

UNIVERSIDAD COMPLUTENSE DE MADRID
FACULTAD DE CIENCIAS FÍSICAS

DEPARTAMENTO DE ARQUITECTURA DE COMPUTADORES Y AUTOMÁTICA



TRABAJO DE FIN DE GRADO

Código de TFG: ACA02

Control de sistemas multiagente y sus aplicaciones

Control of multi-agent systems and their applications

Supervisor/es: Lía García Pérez, Juan Jiménez

Alejandro Soler Gonzálvez

Grado en Física

Curso académico 2024-25

Convocatoria Ordinaria

Resumen:

Este trabajo aborda el diseño y simulación de un sistema multiagente para la exploración y estimación de un campo escalar desconocido. Se estudia cómo un conjunto de agentes móviles puede colaborar para recolectar información del entorno y construir una representación del campo mediante técnicas de interpolación estadística. A través de la cooperación y el uso de modelos probabilísticos, los agentes son capaces de identificar regiones de interés y mejorar progresivamente su conocimiento del entorno. Se presentan los fundamentos teóricos, la implementación del sistema y los resultados obtenidos mediante simulaciones computacionales.

Abstract:

This work addresses the design and simulation of a multi-agent system for exploring and estimating an unknown scalar field. It investigates how a set of mobile agents can collaborate to gather information from the environment and build a representation of the field using statistical interpolation techniques. Through cooperation and the use of probabilistic models, the agents are able to identify regions of interest and progressively improve their knowledge of the environment. The theoretical foundations, system implementation, and results obtained through computational simulations are presented.

Índice

1. Introducción	4
1.1. Motivación y contexto del problema	4
1.2. Objetivos del trabajo	4
2. Marco Teórico	5
2.1. Fundamentos de Kriging y su interpretación como Proceso Gaussiano	5
2.2. Comparativa entre métodos de interpolación	5
3. Formulación del problema y dinámica del sistema	5
3.1. Descripción del campo escalar y objetivos de exploración	5
3.2. Dinámica y control de los agentes	6
3.3. Comunicación local	6
3.4. Representación de la memoria compartida	6
4. Modelado probabilístico del campo y Kriging	7
4.1. Campos aleatorios gaussianos	7
4.2. Construcción del modelo de covarianza y estimación de hiperparámetros	7
4.3. Semivariograma empírico y modelo gaussiano	7
4.3.1. Definición del semivariograma empírico	7
4.3.2. Modelo de semivariograma gaussiano	8
4.4. Kriging simple, ordinario y universal	8
4.5. Derivación de las ecuaciones desde procesos gaussianos	9
4.5.1. Estimador de Kriging	9
4.5.2. Varianza asociada a la predicción	10
4.5.3. Estimación de los coeficientes del modelo ($\hat{\beta}$)	10
4.6. Implementación práctica con PyKrige	10
5. Estrategias de exploración y selección de puntos	11
5.1. Algoritmos distribuidos de selección en sistemas multiagente	11
6. Arquitectura del algoritmo y comparación de metodologías	12
6.1. Enfoques de implementación	12
6.1.1. Método original de Kahn et al. (2015)	12
6.1.2. Versión propuesta	12
6.2. Cambios adoptados respecto al método de Kahn et al.	13
6.3. Implementación detallada de la versión propuesta	13
6.3.1. Algoritmo general e implementación	13
7. Simulación y resultados	14
7.1. Parámetros de la simulación	14
7.2. Resultados	15
7.2.1. Análisis de convergencia	18
7.2.2. Sensibilidad al parámetro de curiosidad b	18
8. Conclusiones y trabajos futuros	20
8.1. Conclusiones	20
8.2. Trabajos futuros	20

1. Introducción

1.1. Motivación y contexto del problema

La estimación y localización de máximos globales en campos escalares desconocidos es un problema de gran relevancia en ámbitos como la detección de focos contaminantes, fuentes térmicas o químicas, yacimientos naturales o emisiones radiactivas. Estas tareas se enfrentan a restricciones físicas y logísticas que impiden un muestreo exhaustivo del dominio, lo que motiva el desarrollo de estrategias de exploración adaptativa y modelado probabilístico.

En este contexto, los sistemas multiagente (MAS) han demostrado ser una solución eficaz y escalable. Su capacidad para distribuir la carga sensorial y computacional, así como para adaptarse al entorno de forma descentralizada mediante cooperación local, permite construir representaciones precisas del campo sin requerir cobertura completa ni comunicaciones centralizadas [6, 8].

A diferencia de enfoques basados en ascenso de gradiente [9, 13], que tienden a converger hacia óptimos locales debido a la naturaleza local de la información del gradiente, el enfoque de este proyecto explota modelos probabilísticos del campo, como el Kriging, que permiten combinar exploración (buscar donde más incertidumbre haya) y explotación (ir al máximo del campo).

El enfoque que se adopta en este trabajo se inspira en la propuesta de Kahn et al. [10], en la que se busca el máximo de un campo escalar desconocido mediante un sistema distribuido de agentes móviles. Cada agente realiza mediciones locales del campo en su entorno, y mediante el intercambio de información con sus vecinos, construye un modelo probabilístico del campo utilizando interpolación por Kriging. Este modelo no solo proporciona una estimación del campo en regiones no muestreadas, sino que también cuantifica la incertidumbre asociada a dicha predicción. A partir de este conocimiento, cada agente decide iterativamente el próximo punto donde tomar una nueva medición, seleccionándolo según un criterio de adquisición que será descrito en detalle en la Sección 5. Este criterio busca equilibrar la explotación de zonas prometedoras y la exploración de regiones con alta incertidumbre, de forma completamente descentralizada y cooperativa.

1.2. Objetivos del trabajo

El objetivo general de este trabajo es diseñar, implementar y analizar un sistema multiagente autónomo capaz de localizar el máximo global de un campo escalar desconocido y estacionario mediante Kriging. Los objetivos específicos son:

- Modelar el campo a partir de mediciones locales utilizando un estimador de Kriging formulado como un proceso gaussiano con covarianza [14].
- Diseñar y analizar métodos de selección de puntos de muestreo que combinen exploración (zonas con alta incertidumbre) y explotación (zonas cercanas al máximo estimado), en línea con el criterio propuesto en [10].
- Implementar una ley de control cooperativa para guiar a los agentes hacia sus respectivos objetivos de muestreo, evitando colisiones y aprovechando la comunicación local entre vecinos [3].
- Evaluar el rendimiento del sistema mediante simulaciones numéricas, comparando su eficacia en términos de eficiencia de muestreo, convergencia y escalabilidad.

A lo largo de este trabajo se presenta, en primer lugar, el marco teórico 2 necesario para contextualizar el problema. A continuación, se formula el problema abordado 3 y se describe la dinámica de los agentes que componen el sistema. Posteriormente, se detalla el modelado probabilístico del

campo escalar y se profundiza en la construcción del modelo de Kriging 4. Se analizan diferentes estrategias de exploración y selección de puntos 5, lo que permite introducir el algoritmo de Kahn et al. y la versión modificada propuesta en este trabajo 6. Finalmente, se presentan los resultados obtenidos a través de simulaciones numéricas 7, junto con su análisis y discusión, incluyendo una reflexión sobre posibles líneas de mejora y extensión para trabajos futuros 8.

2. Marco Teórico

2.1. Fundamentos de Kriging y su interpretación como Proceso Gaussiano

El Kriging es un método estadístico de interpolación óptima lineal y no sesgada, formulado originalmente en geoestadística por Matheron [11] como el *Best Linear Unbiased Predictor* (BLUP). Dado un conjunto de observaciones, estima el valor de una variable aleatoria en puntos no muestreados, utilizando la estructura de covarianza espacial del campo.

Desde la perspectiva de procesos gaussianos (GP), un campo escalar puede modelarse como una realización de un proceso estocástico definido por una media y una función de covarianza [14]. Esta formulación bayesiana permite construir la distribución posterior del campo condicionado a las observaciones, proporcionando tanto la media estimada como la incertidumbre asociada. El Kriging simple, ordinario y universal pueden obtenerse como casos particulares de regresión bayesiana mediante GP con distintos modelos de media.

2.2. Comparativa entre métodos de interpolación

Diversos métodos han sido propuestos para la interpolación de campos espaciales. Franke [5] ofrece una comparativa empírica entre técnicas clásicas como la interpolación bilineal, el ajuste por splines y las funciones de base radial (RBF), destacando las diferencias en precisión y robustez frente a irregularidades topológicas. Buhmann [2] profundiza en la teoría de RBFs y su relación con el Kriging, señalando que si bien ambas técnicas utilizan funciones *kernel*, solo el Kriging proporciona una estimación probabilística y un análisis de incertidumbre.

Frente a estos métodos, el Kriging destaca por su capacidad para integrar la información espacial y modelar la incertidumbre, siendo particularmente adecuado para entornos parcialmente observados y con ruido, como los que se abordan en este trabajo.

3. Formulación del problema y dinámica del sistema

3.1. Descripción del campo escalar y objetivos de exploración

Sea $f : D \subset \mathbb{R}^m \rightarrow \mathbb{R}$ un campo escalar continuo y desconocido definido sobre un dominio compacto D . Este campo se modela como una única realización de un proceso gaussiano estacionario de segundo orden. Bajo esta hipótesis, se asume una media constante μ y una función de covarianza $k(x, x') = \mathbb{E}[(f(x) - \mu)(f(x') - \mu)]$.

El objetivo del sistema multiagente es identificar el máximo global del campo f , es decir:

$$x^* = \arg \max_{x \in D} f(x), \quad (1)$$

usando únicamente medidas puntuales realizadas por los agentes, sin acceso a la expresión analítica de f , tan solo a la emulación del campo construido mediante Kriging.

3.2. Dinámica y control de los agentes

Se consideran N agentes móviles indexados por $i \in \{1, \dots, N\}$, cuya posición en el tiempo continuo $t \geq 0$ se denota $x_i(t) \in D$. Cada agente sigue una dinámica de tipo masa-amortiguador gobernada por la ecuación:

$$M\ddot{x}_i(t) + C(x_i, \dot{x}_i)\dot{x}_i(t) = u_i(t), \quad (2)$$

donde $M > 0$ es la masa del agente, C representa el término de amortiguamiento dependiente del estado y $u_i(t)$ es la señal de control. Esta ecuación modela el comportamiento físico del agente como un sistema dinámico de segundo orden, ampliamente utilizado en control distribuido de enjambres [3, 10].

El término de control $u_i(t)$ se construye con tres componentes principales:

$$u_i = C(x_i, \dot{x}_i)\dot{x}_i(t) - k_1(\dot{x}_i - \dot{x}_i^d) + 2k_2 \sum_{j \neq i}^N \frac{x_i - x_j}{q} e^{-\frac{\|x_i - x_j\|^2}{q}} - k_3(x_i - x_i^d), \quad (3)$$

donde x_i^d y $\dot{x}_i^d$ son la posición y velocidad objetivo deseadas del agente y $k_1, k_2, k_3, q > 0$ son parámetros de diseño que regulan la velocidad del agente (k_1), la repulsión entre agentes (q, k_2) y la atracción al destino (k_3), respectivamente[13].

3.3. Comunicación local

Los agentes disponen de un radio de comunicación limitado $r > 0$. Definimos el conjunto de vecinos del agente i en el instante discreto t_k como:

$$\mathcal{N}_i(t_k) = \{j \in \{1, \dots, N\} \mid \|x_i(t_k) - x_j(t_k)\| \leq r\}. \quad (4)$$

La arquitectura del sistema es completamente distribuida: no existe un nodo central, y la información fluye únicamente entre vecinos. Cada agente decide localmente si realizar una medición $f(x_i(t_k))$, y, en caso afirmativo, retransmite el dato a sus vecinos. Esta estructura es escalable y robusta frente a fallos individuales [4, 6].

3.4. Representación de la memoria compartida

Cada agente i mantiene una memoria local $S_i(t_k)$ que contiene los datos propios y los recibidos de sus vecinos hasta el tiempo t_k :

$$S_i(t_k) = \bigcup_{l=0}^k \{(x_j(t_l), f(x_j(t_l))) \mid j \in \mathcal{N}_i(t_l) \cap \mathcal{M}(t_l)\}, \quad (5)$$

donde $\mathcal{M}(t_l)$ representa el conjunto de agentes que han tomado medida en t_l . Esta memoria compartida permite que cada agente construya su propio modelo local del campo utilizando técnicas de Kriging a partir de la información recopilada.

Esta formulación proporciona la base matemática sobre la que se construyen las estrategias de inferencia y control descritas en secciones posteriores.

4. Modelado probabilístico del campo y Kriging

4.1. Campos aleatorios gaussianos

Sea $\phi : \mathcal{D} \subset \mathbb{R}^m \rightarrow \mathbb{R}$ un campo escalar continuo definido sobre un dominio compacto $\mathcal{D}$. Se modela ϕ como un campo aleatorio gaussiano (CAG), es decir, una colección de variables aleatorias $\{\phi(x)\}_{x \in \mathcal{D}}$ tal que para cualquier conjunto finito de puntos $\{x_1, \dots, x_n\} \subset \mathcal{D}$, el vector aleatorio $\phi = (\phi(x_1), \dots, \phi(x_n))^\top$ sigue una distribución normal multivariante. Esta se caracteriza por una media $\mu(x)$ y una función de covarianza $k(x, x') = \mathbb{E}[(\phi(x) - \mu(x))(\phi(x') - \mu(x'))]$.

4.2. Construcción del modelo de covarianza y estimación de hiperparámetros

Se adopta una función de covarianza estacionaria e isotrópica (en nuestro caso) de la forma:

$$k(x, x') = \sigma_z^2 \exp \left(- \sum_{i=1}^m \frac{1}{\theta_i} |x_i - x'_i|^{q_i} \right), \quad (6)$$

donde σ_z^2 es la varianza marginal, θ_i es el parámetro de escala (longitud de correlación) y $q_i \in [0, 2]$ determina la suavidad. Esta función satisface las condiciones de positividad-definida necesarias para definir un proceso gaussiano válido [15]. Los hiperparámetros $(\sigma_z^2, \theta_i, q_i)$ se estiman mediante ajuste del semivariograma empírico, métodos de mínimos cuadrados o máxima verosimilitud.

4.3. Semivariograma empírico y modelo gaussiano

El semivariograma es una función que permite cuantificar la variabilidad de un campo escalar en función de la distancia entre los puntos. Su papel es fundamental en la construcción del modelo de covarianza en Kriging, ya que proporciona una estimación empírica de cómo varían los valores del campo según la separación espacial.

4.3.1. Definición del semivariograma empírico

El semivariograma empírico se define como:

$$\gamma(h) = \frac{1}{2N(h)} \sum_{i=1}^{N(h)} [Z(x_i) - Z(x_i + h)]^2 \quad (7)$$

donde:

- h es la distancia (o *lag*) entre dos puntos del campo.
- $N(h)$ es el número de pares de puntos separados por la distancia h .
- $Z(x_i)$ y $Z(x_i + h)$ son los valores del campo en los puntos x_i y $x_i + h$, respectivamente.

Este cálculo produce una curva empírica que refleja cómo varía la semivarianza del campo a medida que aumenta la distancia.

4.3.2. Modelo de semivariograma gaussiano

En nuestro caso, se ha seleccionado el modelo de semivariograma gaussiano, que es especialmente adecuado para campos donde la correlación decrece suavemente con la distancia. La expresión matemática del modelo gaussiano es:

$$\gamma(h) = Ng + \sigma_z^2 \left[1 - \exp \left(- \left(\frac{h}{\theta} \right)^2 \right) \right] \quad (8)$$

donde:

- σ_z^2 es el **sill** (meseta), esto es, la varianza total a la que tiende el semivariograma cuando h es grande.
- θ es el **range** o *parámetro de escala*. Controla la rapidez con que decae la correlación espacial: cuanto mayor es θ , más lentamente disminuye la correlación. En un modelo gaussiano, por ejemplo, la correlación se vuelve prácticamente nula sólo cuando $h \gtrsim 3\theta$.
- N_g es el **nugget**, que representa la varianza no explicada a muy corta distancia (ruido instrumental, micro-variabilidad, etc.); equivale al valor del semivariograma al tomar $h \rightarrow 0$.
- h es la distancia (lag) entre dos ubicaciones del campo.

En nuestro caso y ejemplo particular, veremos que todos estos hiperparámetros, que Kahn sabe *a priori*, nosotros, con el objetivo de ser lo más generales posibles, no los definiremos en el código, y dejaremos que se actualicen automáticamente.

4.4. Kriging simple, ordinario y universal

Siguiendo la formulación del Kriging, el campo se puede modelar de la siguiente forma:

$$\phi(x) = \mu(x) + Z(x), \quad (9)$$

donde $\mu(x)$ es la función de media del campo escalar, que representa el comportamiento sistemático o tendencia del campo en la posición x y $Z(x)$ es un proceso gaussiano centrado con media cero ($\mu = 0$) que captura las variaciones aleatorias o residuales alrededor de la tendencia.

- **Kriging simple:** $\mu(x) = \mu$ conocida.
- **Kriging ordinario:** $\mu(x) = \mu$ constante desconocida.
- **Kriging universal:** $\mu(x) = r(x)^\top \beta$, con $r(x)$ funciones base (por ejemplo, polinomios), donde $r(x)$ es un vector de funciones de regresión conocidas, β es un vector de parámetros deterministas

Esta clasificación sigue la formulación original de Matheron [11] y se encuentra desarrollada en detalle en obras como [15].

4.5. Derivación de las ecuaciones desde procesos gaussianos

En este apartado se presenta la derivación del estimador de Kriging desde la formulación bayesiana de los procesos gaussianos, siguiendo la exposición de [14] y su adaptación al contexto multiagente propuesta por [10]. Toda esta explicación se hará sin tener en cuenta un posible ruido residual.¹

Se considera un conjunto de n observaciones del campo escalar, tomadas por los agentes en las posiciones $x_1, \dots, x_n \in \mathcal{D}$, modeladas como:

$$y_i = \phi(x_i)$$

donde $\phi(x)$ es una realización de un campo aleatorio gaussiano. En este marco, las observaciones $\mathbf{y} = (y_1, \dots, y_n)^\top$ y el valor del campo en una nueva posición x siguen una distribución gaussiana conjunta²:

$$\begin{pmatrix} \mathbf{y} \\ \phi(x) \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} R\boldsymbol{\beta} \\ r(x)^\top \boldsymbol{\beta} \end{pmatrix}, \begin{pmatrix} \mathbf{K} & \mathbf{k}_x \\ \mathbf{k}_x^\top & k(x, x) \end{pmatrix} \right)$$

donde:

- $\mathbf{K} \in \mathbb{R}^{n \times n}$ es la matriz de covarianzas entre las posiciones muestreadas: $K_{ij} = k(x_i, x_j)$,
- $\mathbf{k}_x \in \mathbb{R}^n$ es el vector de covarianzas entre el nuevo punto y las observaciones: $k_x^{(i)} = k(x, x_i)$,
- $R \in \mathbb{R}^{n \times p}$ es la matriz de funciones de regresión evaluadas en los puntos $x_1, \dots, x_n$,
- $r(x) \in \mathbb{R}^p$ son las funciones de regresión evaluadas en el punto de predicción.

4.5.1. Estimador de Kriging

Aplicando la fórmula del valor esperado de una distribución gaussiana condicional, se obtiene el estimador de Kriging:

$$\hat{\phi}(x) = r(x)^\top \hat{\boldsymbol{\beta}} + \mathbf{k}_x^\top \mathbf{K}^{-1} (\mathbf{y} - R\hat{\boldsymbol{\beta}}) \quad (10)$$

La fórmula general para el valor esperado de una distribución normal condicional es:

$$\mathbb{E}[\mathbf{Y} \mid \mathbf{X}] = \mu_Y + \Sigma_{YX} \Sigma_{XX}^{-1} (\mathbf{x} - \mu_X) \quad (11)$$

Esta expresión corresponde al valor esperado condicionado en una distribución gaussiana multivariante [1].

¹Si se tuviera en cuenta este ruido, tan solo se tomaría $y_i = \phi(x_i) + \epsilon_i$, y allí donde se pone la matriz de covarianza $\mathbf{K}$, se sustituye por $\mathbf{K} + \sigma_n^2 \mathbf{I}$, donde $\sigma_n^2 \mathbf{I}$ es el término de ruido blanco gaussiano, que en geoestadística se interpreta como el nugget del semivariograma.

²Una distribución gaussiana conjunta describe el comportamiento de un conjunto de variables aleatorias que siguen una distribución normal multivariada. Si $\mathbf{X}$ y $\mathbf{Y}$ son vectores aleatorios conjuntos que siguen una distribución normal multivariada con medias μ_X y μ_Y , respectivamente, y matriz de covarianza conjunta:

$$\begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix} \right)$$

4.5.2. Varianza asociada a la predicción

La varianza asociada a la predicción se obtiene a partir de la fórmula de la varianza condicional en una distribución normal multivariada:

$$\text{Var}[\mathbf{Y} \mid \mathbf{X}] = \Sigma_{YY} - \Sigma_{YX} \Sigma_{XX}^{-1} \Sigma_{XY} \quad (12)$$

En el contexto del modelo de Kriging, esto se traduce en:

$$\text{Var}[\hat{\phi}(x)] = k(x, x) - \mathbf{k}_x^\top \mathbf{K}^{-1} \mathbf{k}_x \quad (13)$$

Esta fórmula garantiza que la incertidumbre en la predicción se reduzca al considerar la correlación espacial entre los puntos muestreados y el punto a predecir. Dado que los puntos cercanos tienen mayor correlación, su contribución en la reducción de la varianza es mayor.

4.5.3. Estimación de los coeficientes del modelo ($\hat{\beta}$)

La fórmula de estimación de los coeficientes del modelo proviene del método de mínimos cuadrados ponderados. La expresión a minimizar³ es:

$$J(\beta) = (\mathbf{y} - R\beta)^\top \mathbf{K}^{-1} (\mathbf{y} - R\beta) \quad (14)$$

Derivando respecto a β e igualando a cero, se obtiene:

$$R^\top \mathbf{K}^{-1} \mathbf{y} = (R^\top \mathbf{K}^{-1} R) \hat{\beta} \quad (15)$$

Despejando, llegamos a:

$$\hat{\beta} = (R^\top \mathbf{K}^{-1} R)^{-1} R^\top \mathbf{K}^{-1} \mathbf{y} \quad (16)$$

Esta expresión garantiza que los coeficientes obtenidos minimicen el error cuadrático ponderado, teniendo en cuenta la estructura de covarianza del campo.

4.6. Implementación práctica con PyKrige

La implementación computacional del método de Kriging se ha llevado a cabo utilizando la librería `PyKrige` en su versión 1.7.2 [12], que proporciona una interfaz en `Python` para la interpolación geoestadística en una, dos y tres dimensiones. Esta librería soporta variantes como Kriging ordinario, universal y con deriva externa, así como distintos modelos de variograma (gaussiano, exponencial, esférico, entre otros).

A continuación, se muestra un ejemplo básico de aplicación de Kriging ordinario en dos dimensiones:

```
from pykrige.ok import OrdinaryKriging

OK = OrdinaryKriging(
    x, y, z,
    variogram_model="gaussian",
    variogram_parameters={'sill': 1.0, 'range': 30.0, 'nugget': 0.1},
```

³Esta función de coste proviene del método de mínimos cuadrados ponderados. Dado que las observaciones están correlacionadas espacialmente, es necesario considerar la estructura de covarianza del campo. La matriz de covarianza $\mathbf{K}$ actúa como factor de ponderación, corrigiendo el error cuadrático en función de la correlación entre las observaciones [14].

```

    enable_plotting=True
)
z_pred, var = OK.execute("grid", xgrid, ygrid)

```

En este ejemplo, x , y y z representan los datos espaciales muestreados; el modelo de variograma se puede definir con parámetros ajustados manualmente. En nuestro caso, con el objetivo de hacerlo lo más general posible, no vamos a definir los parámetros del variograma, con el objetivo de que la simulación que se ejecute los ajuste automáticamente usando esta librería, por lo que no definiríamos la línea de parámetros.

PyKrige devuelve tanto la predicción del campo interpolado (z_pred) como la varianza de predicción (var), lo que permite cuantificar la incertidumbre asociada a cada punto del dominio.

Consideración técnica sobre la matriz de covarianza y uso de la pseudo-inversa

Durante la implementación del método de Kriging con la librería PyKrige, se detectó ocasionalmente un problema de singularidad en la matriz de covarianza generada, principalmente causado por una distribución espacial muy próxima entre ciertos puntos medidos por los agentes. Esta situación provoca que la matriz sea numéricamente singular o mal condicionada, impidiendo el cálculo directo de su inversa mediante métodos convencionales.

Para solventar este inconveniente, se empleó la pseudo-inversa (inversa generalizada de Moore-Penrose) configurando la opción `pseudo_inv=True` en la función de interpolación de PyKrige. Este enfoque asegura la robustez numérica de la interpolación, proporcionando estabilidad y permitiendo que el sistema multiagente mantenga una convergencia consistente hacia el máximo global del campo, tal como se ha reportado en la sección de resultados.

5. Estrategias de exploración y selección de puntos

5.1. Algoritmos distribuidos de selección en sistemas multiagente

Siguiendo a Kahn et al. [10], cada agente i decide en la iteración k cuál será su *próximo* punto de muestreo $x_i^{(k+1)}$ empleando una de las dos políticas descritas a continuación. Sea $x_i^{(k)}$ su posición actual y $\mathcal{D}$ el dominio de búsqueda.

Estrategia 1: buscar el máximo de la media El agente se dirige al lugar donde su modelo predice el valor medio más alto:

$$x_i^{(k+1)} = \arg \max_{x \in \mathcal{D}} \hat{f}_{i,k}(x), \quad (17)$$

con $\hat{f}_{i,k}(x)$ la media de Kriging. Esta regla explota la información disponible pero puede concentrar a varios agentes en la misma zona si sus modelos coinciden.

Estrategia 2: minimizar una función de coste penalizada Para fomentar la cobertura se introduce la función

$$J_i^{(k)}(x) = \underbrace{\|x - x_i^{(k)}\|^2}_{\text{costo de desplazarse}} - \underbrace{\sum_{j \in \mathcal{N}_i} \alpha \|x - x_j^{(k)}\|^2}_{\text{repulsión entre agentes}}, \quad (18)$$

donde el primer término penaliza movimientos largos y el segundo empuja al agente lejos de sus vecinos ($\alpha > 0$ regula la intensidad de esta repulsión). El punto candidato debe satisfacer además

el criterio de *curiosidad* /exploración

$$\underbrace{\hat{\phi}_{i,k}(x) + b\sigma_{i,k}(x)}_{\text{función de adquisición}} > f_{\text{máx},k}^i, \quad (19)$$

que exige que la suma de la media $\hat{\phi}_{i,k}$ y b veces la desviación típica $\sigma_{i,k}$ supere el mejor valor observado hasta el momento. El agente elige finalmente

$$x_i^{(k+1)} = \arg \min_{\substack{x \in \mathcal{D} \\ \text{cond. (19)}}} J_i^{(k)}(x). \quad (20)$$

- $\alpha > 0$: peso de la repulsión entre agentes (cobertura vs. cooperación).
- b : parámetro de *curiosidad* (exploración vs. explotación).
- $f_{\text{máx},k}^i$: mejor valor medido por el equipo hasta la iteración k .

6. Arquitectura del algoritmo y comparación de metodologías

6.1. Enfoques de implementación

6.1.1. Método original de Kahn et al. (2015)

Kahn et al. [10] presentan un esquema totalmente distribuido en el que cada agente:

1. Recoge mediciones propias y de sus vecinos dentro de un radio r , el cual abarca todo el campo, por lo que en su enfoque, el radio sería 'infinito'.
2. Reconstruye un modelo Kriging universal para cada agente.
3. Elige el siguiente punto con un optimizador global DIRECT sujeto a (20).
4. Se desplaza según una ley de control cooperativa (3).

La búsqueda de puntos de mejora se resuelve en todo el dominio continuo, sin rejillas discretas, y sin un almacenamiento temporal de destinos, lo que garantiza exploración exhaustiva pero con elevado coste computacional.

6.1.2. Versión propuesta

Antes de nada, debemos mencionar que la versión de Kahn no se podía implementar correctamente, debido a la falta de información en implementaciones de ciertas partes del algoritmo.⁴ De igual forma, el intento de implementación de este código daba un resultado no deseado, en el que no convergía el código en la mayoría de ocasiones que se ejecutaba, llegando incluso a funcionar de manera distinta dependiendo de en qué ordenador se ejecutara.

Debido a todos estos contratiempos, aquí se presenta una versión que sigue la filosofía de Kahn, con los siguientes cambios respecto a su metodología:

⁴Por ejemplo, al implementar la función de coste con el optimizador global DIRECT [7]—disponible en `scipy.optimize`—surge el problema de que DIRECT es un método *sin* restricciones. Kahn et al. [10] indican que utilizan DIRECT, pero no especifican cómo incorporan la condición (19). En la práctica, ello exige (i) añadir un término de penalización al coste cuando la restricción se viola o, alternativamente, (ii) filtrar a posteriori los puntos generados por DIRECT y refinar la búsqueda. El artículo de Kahn no aclara cuál de estas dos opciones adopta.

6.2. Cambios adoptados respecto al método de Kahn et al.

Implementación del modelo. En la simulación calculamos un único modelo de Kriging global a partir de todos los datos disponibles. Con comunicación perfecta esto produce la misma superficie que reconstruir N veces el modelo con los mismos puntos, pero reduce el coste computacional del experimento. Obsérvese que en una implementación física se mantendría el cálculo local de cada agente, como proponen Kahn et al. [10], para evitar un punto único de fallo.

- **Búsqueda en rejilla discreta.** Sustituimos la exploración continua con DIRECT por una búsqueda sobre una rejilla regular de un tamaño acorde a la precisión que queramos (cuanto más precisa, más tarda en ejecutarse debido al coste computacional). En nuestro código empleamos una acorde al tamaño del campo, $(51 \times 51)(-)$. Con ello controlamos exactamente cuántos puntos se evalúan y obtenemos un coste de cómputo predecible sin perder apenas precisión al refinar la resolución.
- **Filtrado y asignación única de puntos.** Mantenemos un conjunto global de *explored_points* para descartar cualquier coordenada ya muestreada, y un conjunto *targets_asignados* por iteración para impedir que dos agentes compitan por el mismo punto. Así logramos una cobertura más ordenada y evitamos redundancias.
- **Ciclo de medición síncrono.** En lugar de un muestreo asíncrono por agente, seguimos un ciclo claro: (i) reconstruir Kriging global, (ii) asignar todos los destinos, (iii) mover todos los agentes hasta su target, (iv) medir simultáneamente y actualizar datos. Esto simplifica la lógica e incluye siempre las mediciones más recientes en el modelo global.

6.3. Implementación detallada de la versión propuesta

6.3.1. Algoritmo general e implementación

El algoritmo principal utilizado se puede ver en la figura [Algoritmo 1](#):

Criterio de parada

El bucle principal se interrumpe en la primera de estas condiciones:

1. **Sin puntos válidos.** La máscara de mejora queda vacía,

$$\mathcal{M} = \{(x, y) \mid \hat{\phi}(x, y) + b \hat{\sigma}(x, y) > f_{\max}\} = \emptyset$$

es decir, no existen coordenadas donde la función de adquisición $(\hat{\phi}(x, y) + b \hat{\sigma}(x, y))$ supere el máximo observado hasta el momento.

2. **Iteraciones máximas.** Se alcanza $k = k_{\max}$ (por ejemplo, 300), garantizando que el algoritmo termine incluso si siempre surgieran nuevos candidatos.

Este doble criterio asegura que el algoritmo no siga iterando cuando no haya mejora posible, y que el proceso se detenga cuando llegue a 300 iteraciones, para evitar un bucle que tarde excesivamente.

Algoritmo 1 Algoritmo del código propuesto

- 1: Inicializar agentes $\{\mathbf{p}_i\}$ con posiciones y mediciones iniciales.
- 2: **for** $k = 1$ **to** $k_{\text{máx}}$ **do**
- 3: Reconstruir kriging global sobre el dominio de datos recogidos $\mathcal{D}$:

$$\hat{\phi}, \hat{\sigma} \leftarrow \text{OrdinaryKriging}(\mathcal{D})$$

- 4: Seleccionamos los puntos que cumplen la condición (19) y los añadimos en $\mathcal{M}$

$$\mathcal{M} = \{(x, y) \in \mathcal{G} \mid \hat{\phi}(x, y) + b \hat{\sigma}(x, y) > f_{\text{máx}}\}$$

- 5: **if** $\mathcal{M} = \emptyset$ **then break** Si no hay puntos de mejora, se para la simulación.
- 6: **end if**
- 7: **for** cada agente i **do**
- 8: Elegir destino

$$x_i^d = \arg \min_{(x, y) \in \mathcal{M} \setminus \mathcal{E}} \left(\|\mathbf{p}_i - (x, y)\|^2 - \alpha \sum_{j \neq i} \|\mathbf{p}_j - (x, y)\|^2 \right)$$

- 9: **end for**
 - 10: Mover todos los agentes según ley de control cooperativa (3) hasta sus x_i^d
 - 11: Cada agente mide en x_i^d , actualizar $\mathcal{D}$ y marcar $(x_i^d) \in \mathcal{E}$, donde $\mathcal{E}$ son los puntos destino que ya han sido visitados.
 - 12: **end for**
-

7. Simulación y resultados

7.1. Parámetros de la simulación

Se han fijado los siguientes valores en dimensiones arbitrarias:

- Dominio: $[0, 50] \times [0, 50]$.
- Campo sintético: suma de tres gaussianas con parámetros:

$$forma : \phi(x, y) = \sum_{i=1}^3 A_i \exp\left(-\frac{(x - c_{x,i})^2 + (y - c_{y,i})^2}{2\sigma_i^2}\right),$$

donde los $(A_i, c_{x,i}, c_{y,i}, \sigma_i)$ son:

Pico i	A_i	$c_{x,i}$	$c_{y,i}$	σ_i
1	1.2	15	15	10
2	1.0	40	35	10
3	1.0	10	35	10

- Agentes: $N = 3$, posiciones iniciales $(5, 5)$, $(45, 5)$, $(25, 45)$.
- Dinámica: $M = 1$, $C = 0,001$, $k_1 = 47$, $k_2 = 50$, $k_3 = 3000$, $q = 0,1$; Paso temporal $T = 0,01$, $v_{\text{máx}} = 2,0$, $\varepsilon = 0,01$ (distancia aceptable al punto de destino para tomar una medida,), $b = 2$. La elección de estos parámetros es la misma que la de Kahn, menos para el parámetro b que se ha usado $b = 2$, ya que es el valor que mejor combina la exploración con la explotación, como veremos al final del apartado 7.

- Rejilla 51 X 51 (por lo que se evalúan 2601 puntos).

El diagrama del flujo de código ejecutado se muestra en la figura 1.




Figura 1: Diagrama de flujo del código ejecutado.

7.2. Resultados

A continuación se muestran los resultados obtenidos tras ejecutar una sola simulación con los parámetros descritos anteriormente. Para ilustrar la evolución del método, incluimos mapas del

campo interpolado, de la incertidumbre, la curva de convergencia y las trayectorias finales de los agentes.

Evolución por iteraciones. En la Tabla 1 se recogen algunos hitos del registro de consola durante la simulación para este caso:

Iteración	Error campo	Error posición
10	0.7870	10.6042
20	0.7799	37.0412
30	0.7528	9.6876
40	0.6978	9.8717
50	0.5784	5.6080
60	0.3472	4.6098
70	0.1644	3.6674
80	—	sin puntos válidos

Cuadro 1: Evolución de métricas clave durante la simulación.

Tanto el error del campo como el error de posición se han calculado midiendo el error entre la estimación del Kriging, y el valor real del campo. En este caso, se observa que tras 79 iteraciones (la número 80 es en la que ya no quedan más puntos válidos de muestreo), la búsqueda de nuevos puntos finaliza y el algoritmo se detiene.


Resultados:

- Máximo global real: $\phi^* = 1,3691$ en (14,3, 18,6).
- Máximo estimado final (OK global): $\hat{\phi}^* = 1,3683$ en (14,0, 19,0).
- Posiciones finales de los agentes:
 - Agente 1: (14,00, 18,00)
 - Agente 2: (14,00, 19,00)
 - Agente 3: (13,00, 21,00)


Como puede observarse en la figura 2a, los agentes finalizan su movimiento en posiciones próximas al máximo del campo, sin llegar a superponerse entre sí. Dado que el dominio del campo es $[0, 50] \times [0, 50]$ y se discretiza mediante una rejilla de tamaño 51×51 , cada celda de la rejilla representa un paso de 1 unidad en ambas direcciones (resolución espacial de 1). Por esta razón, las coordenadas finales de los agentes están restringidas a valores enteros, y no se observan decimales en sus posiciones. Además, esta discretización implica que dos agentes que ocupen celdas adyacentes (pero no la misma) no se consideran superpuestos, lo que garantiza la no colisión bajo esta precisión.

Teniendo en cuenta el paso temporal, se ha calculado el tiempo físico que tardarían en llegar a este máximo, lo que si se toman unidades del Sistema Internacional para todos los parámetros, serían 164,24 s, sin embargo, como estamos tratando el tema de manera adimensional, se ha calculado que el paso temporal se ejecutaría 16424 veces, hasta llegar a la convergencia.

Se observa en 2a que si los agentes se distribuyen inicialmente desde posiciones bien repartidas en el campo, cada uno explora una parte distinta de éste, lo cual es una ventaja del enfoque multiagente.




(a) Trayectorias finales de los agentes sobre el campo real $\phi(x, y)$. Puntos verdes = posiciones iniciales, cruces negras = posiciones finales.




(b) Mapa de incertidumbre final σ_{pred} .

Figura 2: (a) Trayectorias de los agentes; (b) Incertidumbre final del modelo Kriging.



(a) Curva de convergencia: error de posición



(b) Mapa del campo interpolado final ϕ_{pred} .

Figura 3: (a) Convergencia de la simulación; (b) Campo final interpolado del modelo Kriging.

Es notable también como en 2b los lugares donde hay una mayor incertidumbre, son aquellos donde los agentes no han tomado medidas, lo cual es coherente con el método utilizado. Para la estimación del campo en 3b, claramente se refleja la realidad de una forma bastante exacta, con menor precisión en los lugares donde más incertidumbre tiene el modelo, y mayor en los lugares que se han tomado medidas. La convergencia se puede observar en 3a, donde se ve un comportamiento convergente, ya que conforme se conoce más del campo, el error va disminuyendo hasta llegar al mínimo de la precisión de la rejilla discreta.

Como se puede observar, se tiene una convergencia clara en este caso en concreto con estos parámetros. Sin embargo, este es un caso concreto, por lo que se procede a hacer un análisis más profundo, ya que la convergencia de este método tiene una alta dependencia en sus parámetros y en sus condiciones iniciales, por lo que un solo caso de éxito no garantiza la fiabilidad del algoritmo.

7.2.1. Análisis de convergencia

Para estudiar la robustez y eficiencia del método, se realizan 100 simulaciones independientes con posiciones iniciales aleatorias y dos configuraciones de agentes: $N = 2$ y $N = 3$ con las mismas constantes que antes. Los criterios de clasificación empleados son:

- **Converge:** termina antes de $k_{\text{máx}} = 300$ iteraciones con error posicional $\|\hat{x}^* - x^*\| < 1$ m.
- **Diverge:** termina antes de $k_{\text{máx}}$ con $\|\hat{x}^* - x^*\| > 2$ m.
- **Otro caso:** Suele pasar cuando se alcanzan las 300 iteraciones y los agentes se quedan 'a mitad' de camino. En general, todos los casos albergados aquí, tendían hacia la convergencia, debido a que su error seguía la tendencia a minimizarse, y las trayectorias de los agentes se dirigían hacia el máximo, quedándose a una corta distancia de alcanzarlo, pero 300 iteraciones eran insuficientes.

Categoría	$N = 2$	$N = 3$
Convergen correctamente (< 1 m)	94	91
Divergen significativamente (> 2 m)	2	3
Terminan en otras condiciones	4	6
Tiempo medio de simulación (segundos)	06.56	07.34

Cuadro 2: Resultados del estudio de convergencia para $N = 2, 3$.

Observamos que, para $N = 2$, un 94 % de las ejecuciones, el algoritmo converge con alta precisión bajo nuestro umbral de 1 m, mientras que sólo un 2 % diverge más allá de 2 m. El resto (4 %) no cumple ninguno de los dos criterios antes de $k_{\text{máx}}$, pero como hemos dicho, tienen tendencia convergente. Para $N = 3$ vemos un comportamiento muy parecido al de $N = 2$ respecto a su convergencia. Por otra parte, el coste computacional se mantiene estable, tardando prácticamente lo mismo de media en ejecutarse los dos códigos con distintos agentes.

Se han realizado algunas simulaciones aumentando el número de agentes, con el objetivo de comprobar su funcionamiento escalando este parámetro. Se muestra el caso de la simulación con 10 agentes.

Caso con $N = 10$ agentes. Se ejecutó con 10 agentes inicializados aleatoriamente en $[0, 50]^2$ con las mismas constantes que antes. En este ejemplo concreto, el algoritmo convergió al máximo global en tan solo 11 iteraciones. Todos los agentes midieron en cada iteración, por lo que se tomaron 110 medidas en total, un número más bajo que el primer ejemplo de la simulación, donde con 3 agentes, convergía en 79 iteraciones, lo cual son 237 medidas en total. Esta disminución de medidas se debe a que al haber más agentes, tienen más conocimiento del campo al estar mejor distribuidos. La Figura 4 muestra las trayectorias seguidas por los 10 agentes hasta la convergencia.

Como se ve en la figura, el tiempo de simulación sigue siendo algo bastante aceptable, por lo que este método no se limita al número de agentes, ya que su coste computacional es el mismo prácticamente.

7.2.2. Sensibilidad al parámetro de curiosidad b

Para este apartado, se evalúa cómo afecta el parámetro de curiosidad b (mismas posiciones iniciales $(5, 5), (45, 5), (25, 45)$) variando $b \in \{0, 1, 2, 3\}$. En la Tabla 3 se resumen las métricas clave




Figura 4: Trayectorias de un experimento extremo con $N = 10$ agentes, convergiendo en 11 iteraciones en aproximadamente 8 segundos.

al finalizar cada simulación.

b	Iter. final	Número de pasos	Error campo	Error posición
0	1	0	0.9178*	Indefinido *
1	15	7349	0.0227	0.5000
2	80	16424	0.1644	0.5000
3	300	47972	0.2014	6.9893

Cuadro 3: Resultados finales para distintas b . (* En $b = 0$ no converge: cada agente permanece en su punto inicial, estimando $\hat{\phi} = 0,4513$ en $(5, 5)$, por lo que los errores quedan sin sentido.)

Análisis y conclusiones.

- **$b = 0$:** Sin curiosidad (solo explotación), los agentes no exploran: la simulación termina tras la primera iteración, estimando $\hat{\phi} = 0,4513$ en su posición inicial. Caso inservible para búsqueda.
- **$b = 1$:** Con moderada curiosidad, completa en 15 iteraciones, mostrando un buen compromiso exploración–explotación.
- **$b = 2$:** Mayor curiosidad extiende exploración a 80 iteraciones, lo que lo hace un buen equilibrio entre explotación y exploración.
- **$b = 3$:** La excesiva curiosidad alarga la simulación hasta 300 iteraciones, provocando *sobreexploración*.

En resumen, valores intermedios $b = 1$ o $b = 2$ ofrecen un equilibrio óptimo: suficiente curiosidad para escapar de mínimos locales y rápida convergencia al máximo global, en la que $b=3$ ofrece una interpolación más fidedigna del campo entero debido a su mayor exploración. Por el contrario, $b = 0$ (sin exploración) y $b \geq 3$ (sobreexploración) resultan inadecuados para este problema.

8. Conclusiones y trabajos futuros

8.1. Conclusiones

Este Trabajo de Fin de Grado ha abordado con éxito el diseño, implementación y evaluación de un sistema multiagente para la exploración y estimación de un campo escalar desconocido mediante técnicas de interpolación estadística basadas en Kriging. La metodología adoptada, inspirada en el enfoque original de Kahn et al. [10], ha sido adaptada y mejorada para resolver problemas prácticos observados en su implementación original, logrando una versión robusta, estable y altamente efectiva.

A partir de las simulaciones realizadas, podemos destacar varias conclusiones importantes. En primer lugar, el sistema propuesto ha demostrado una notable capacidad para identificar correctamente el máximo global del campo, alcanzando errores posicionales inferiores a 1 *unidad* en más del 90 % de las simulaciones realizadas. Este alto nivel de convergencia pone de relieve la efectividad del modelo global de Kriging utilizado en combinación con la estrategia de selección de puntos basada en un criterio que balancea la explotación del máximo local estimado y la exploración de regiones con más alta incertidumbre.

En segundo lugar, hemos evaluado la influencia del parámetro de curiosidad b , responsable del equilibrio entre exploración y explotación. Los resultados obtenidos muestran claramente que valores moderados de este parámetro ($b = 1$ y $b = 2$) ofrecen un balance óptimo, alcanzando una rápida y precisa convergencia al máximo global. Por el contrario, valores extremos como $b = 0$, que eliminan completamente la exploración, y $b = 3$, que inducen una sobreexploración, han resultado ser claramente subóptimos, ralentizando significativamente la convergencia o impidiendo directamente la exploración efectiva del entorno.

Finalmente, cabe destacar la notable escalabilidad del método frente al número de agentes. El caso con $N = 10$ agentes ha convergido en apenas 11 iteraciones, demostrando que el coste computacional permanece bajo control incluso con un elevado número de agentes. Además, la implementación del modelo global de Kriging en lugar de múltiples modelos locales ha reducido significativamente la carga computacional sin comprometer la calidad de las estimaciones.

En conclusión, la metodología desarrollada en este trabajo constituye una solución eficaz y flexible para problemas de localización de máximos en campos escalares desconocidos, aportando claridad respecto al enfoque original y demostrando su potencial para aplicaciones reales en robótica colaborativa, monitorización ambiental y exploración autónoma.

8.2. Trabajos futuros

Aunque los resultados alcanzados son prometedores, se abren diversas líneas de investigación que podrían mejorar y extender aún más el alcance y la aplicabilidad de este trabajo:

- **Optimización continua:** sustituir la rejilla discreta por métodos de optimización continua más sofisticados podría mejorar aún más la precisión en la localización del máximo global, evitando posibles limitaciones de resolución espacial. Sin embargo, habría que establecer el equilibrio entre precisión y tiempo de cómputo.
- **Adaptación dinámica de la curiosidad:** diseñar algoritmos que ajusten automáticamente el parámetro de curiosidad b durante la simulación según métricas en tiempo real, permitiendo adaptarse a distintos escenarios sin intervención manual. Esto dependerá del campo, y de como el usuario final quiera expandir su curiosidad.
- **Comunicación asíncrona y robusta:** investigar mecanismos que permitan a los agentes compartir información de forma más flexible y resistente a latencias y fallos, acercándose más

a condiciones reales de operación. Esto no lo hemos tenido en cuenta en nuestro trabajo, pero la información tarda un tiempo en comunicarse, por lo que habría que investigar como evitar fallos de latencia.

- **Campos dinámicos y multiobjetivo:** extender el enfoque actual a campos que varían con el tiempo o a problemas que involucran múltiples objetivos de búsqueda, incrementando significativamente el espectro de aplicaciones prácticas. Por ejemplo, que después de medir el máximo del campo su objetivo sea minimizarlo, como si fuera una fuente de contaminación.
- **Validación experimental:** implementar el sistema en plataformas robóticas reales para evaluar su rendimiento en condiciones operativas auténticas, con mediciones reales y ambientes menos controlados que los simulados. Para ello habría que tener en cuenta a los agentes con todos sus grados de libertad y restricciones de movimiento.

Estas futuras investigaciones ayudarán a consolidar aún más este enfoque, acercándolo a implementaciones prácticas en contextos industriales, medioambientales y científicos.

Como reflexión final, cabe señalar que este enfoque ofrece un enorme potencial en entornos donde “pensar antes de medir” resulta crucial. Cuando cada evaluación es cara o difícil de obtener, disponer de un método que seleccione de forma inteligente el siguiente punto de muestreo aporta un valor incalculable: maximiza la información obtenida por medición y minimiza el número total de experimentos necesarios. En escenarios de alto coste de adquisición de datos, esa ‘inteligencia’ en la exploración puede marcar la diferencia entre un proceso práctico y uno inviable.

Referencias

- [1] Multivariate normal distribution, May 2025. Page Version ID: 1288576354.
- [2] Martin D. Buhmann. *Radial Basis Functions: Theory and Implementations*. Cambridge University Press, 1 edition, July 2003.
- [3] Chien Chern Cheah, Saing Paul Hou, and Jean Jacques E. Slotine. Region-based shape control for a swarm of robots. *Automatica*, 45(10):2406–2411, October 2009. Publisher: Elsevier BV.
- [4] Jorge Cortes. Distributed Kriged Kalman Filter for Spatial Estimation. *IEEE Transactions on Automatic Control*, 54(12):2816–2827, December 2009.
- [5] Richard Franke. Scattered data interpolation: tests of some methods. *Mathematics of Computation*, 38(157):181–200, 1982. Publisher: American Mathematical Society (AMS).
- [6] Dongbing Gu and Huosheng Hu. Spatial Gaussian process regression with mobile sensor networks. *IEEE transactions on neural networks and learning systems*, 23(8):1279–1290, August 2012.
- [7] D. R. Jones, C. D. Perttunen, and B. E. Stuckman. Lipschitzian optimization without the Lipschitz constant. *Journal of Optimization Theory and Applications*, 79(1):157–181, October 1993.
- [8] Jongeun Choi, Joonho Lee, and Songhwai Oh. Swarm intelligence for achieving the global maximum using spatio-temporal Gaussian processes. In *2008 American Control Conference*, pages 135–140, Seattle, WA, June 2008. IEEE.
- [9] Jongeun Choi, Songhwai Oh, and Roberto Horowitz. Cooperatively learning mobile agents for gradient climbing. In *2007 46th IEEE Conference on Decision and Control*, pages 3139–3144, New Orleans, LA, USA, 2007. IEEE.
- [10] Arthur Kahn, Julien Marzat, Hélène Piet-Lahanier, and Michel Kieffer. Global extremum seeking by Kriging with a multi-agent system. July 2015.
- [11] Georges Matheron. Principles of geostatistics. *Economic Geology*, 58(8):1246–1266, December 1963.
- [12] Benjamin Murphy, Roman Yurchak, and Sebastian Müller. GeoStat-Framework/PyKrige: v1.7.2, May 2024. Language: en.
- [13] P. Ogren, E. Fiorelli, and N.E. Leonard. Cooperative control of mobile sensor networks: Adaptive gradient climbing in a distributed environment. *IEEE Transactions on Automatic Control*, 49(8):1292–1302, August 2004.
- [14] Carl Edward Rasmussen and Christopher K. I. Williams. *Gaussian processes for machine learning*. Adaptive computation and machine learning. MIT Press, Cambridge, Mass., 3. print edition, 2008.
- [15] Michael L. Stein. *Interpolation of Spatial Data*. Springer Series in Statistics. Springer, New York, NY, 1999. ISSN: 0172-7397.